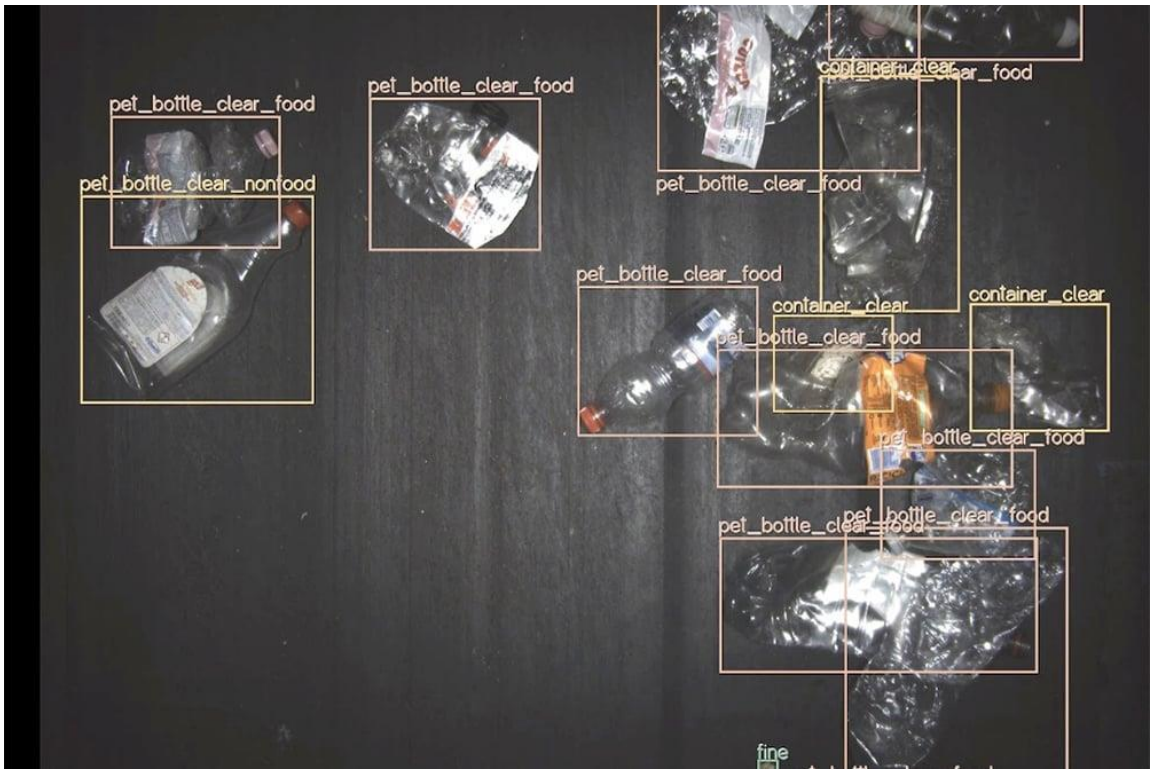


Rapport de Projet

Système Intelligent de Tri Automatisé des Déchets Plastiques par Vision Artificielle

Introduction 3
Organisation du projet et cadrage (Gantt + cahier des charges) 4
1.Contexte, Analyse du Besoin et Solutions Technologiques 6
1.1 Analyse de l'existant et limites 6
1.2 La réponse technologique : pourquoi remplacer le tri NIR par une approche caméra + IA 7
2. Développement du système de tri 9
2.1 Architecture matérielle et principe de fonctionnement du système 9
2.2 Critères de choix des matériels et composants retenus 11
2.3 Constitution du Dataset et Entraînement du Modèle IA 15
2.3.1 Stratégie d'annotation automatisée (supervision faible) 15
2.3.2 Architecture retenue et apprentissage par transfert 15
2.3.3 Hyperparamètres et configuration d'entraînement 16
2.3.4 Résultats obtenus et analyse des performances 17
3. Implémentation embarquée et validation expérimentale 20
3.1 Architecture logicielle 20
3.1.1 Module Caméra et Classification IA 20
3.1.2 Contrôle des pistons 21
3.1.2 Mise en place du système global 27
3.2 Réalisation de la maquette et premiers tests du système 31
Conclusion et perspectives 38
Références Bibliographiques 39

Introduction

Nous nous sommes appuyés sur le fonctionnement du centre de tri Cyrène à Triel-sur-Seine pour comprendre le cheminement des déchets recyclables. Le site Cyrène traite notamment les flux issus du bac jaune (emballages/papiers) et a trié 10 641 tonnes de déchets d'emballages en 2023 (périmètre Valoseine). Chaque centre de tri arbore un fonctionnement qui leur est propre, que ce soit leur propre organisation et leurs équipements spécifiques. Bien qu'il existe des différences structurelles, la majorité des centres partagent des similitudes dans le processus séquentiel : les déchets sont pesés, séparés par taille via un trommel, triés par forme (corps plats/corps creux) et

débarrassés des métaux ferreux. Pour finir, des séparateurs optiques (NIR) affinent le tri selon la matière.

Malgré cette sophistication, nous observons que le processus présente une limite majeure cela se termine systématiquement par une phase de tri manuel en cabine pour corriger les erreurs des machines. En effet, les caméras NIR manquent parfois de précision et laissent passer certains déchets à travers les “mailles du filet”. Plus précisément, le tri optique repose sur une analyse NIR réalisée en quelques millisecondes, comparée à des spectres de référence, mais sa performance dépend fortement des conditions de présentation sur convoyeur et des propriétés des emballages. Cette dépendance à l’intervention humaine engendre des problématiques critiques : d’une part, les coûts d’exploitation sont élevés et les agents subissent une fatigue importante ; d’autre part, le secteur fait face à une forte tension sur l’emploi, rendant le recrutement plus difficile.

Ce qui nous amène à la problématique suivante : C**omment soutenir les opérateurs durant leurs tâches quotidiennes en rendant le tri plus optimisé et moins coûteux grâce à l’IA ?**

Dans ce projet, nous nous plaçons dans une logique de système complémentaire au tri existant, visant une gamme de plastiques définie (**PET, HDPE, PP, PS**) et un fonctionnement en temps réel sur convoyeur. L’objectif est donc de concevoir un système automatisé complémentaire capable de reconnaître visuellement ces plastiques grâce à un modèle de Deep Learning léger, adapté aux contraintes de l’embarqué, afin d’assurer une détection rapide et d’éjecter les déchets ciblés via des actionneurs contrôlés, dans le but de réduire la charge de la cabine de tri.

Cet ouvrage présente l’intégralité de notre démarche pour répondre à cette problématique, que ce soit de l'analyse des besoins initiaux jusqu'au prototypage. Après avoir étudié les solutions existantes, nous justifierons nos choix de conception matérielle et logicielle. Et enfin, nous analyserons les performances réelles de notre système de tri automatisé.

Organisation du projet et cadrage (Gantt + cahier des charges)

Pour éviter de partir dans tous les sens, on a cadré le projet dès le début avec deux choses simples : un diagramme de Gantt et un cahier des charges. Le but est d’avoir une vision claire de ce qu’on doit faire, dans quel ordre et surtout comment on allait juger si ça marche vraiment ou pas.

Le Gantt nous a servi de feuille de route. On a découpé le projet en étapes logiques : compréhension du problème et du contexte industriel, choix du matériel, programmation (caméra/IA, capteurs ultrasons, actionneurs) puis assemblage et tests sur la maquette. Ça nous a aussi permis de suivre l'avancement et de voir tout de suite lorsqu'une partie prenait du retard (surtout partie câblage et intégration).

Titre : Tri des déchets Intelligent

Etudiants : Kelvin RAUD & Artsrun SARGSYAN
Enseignants : Mr.Guillaume RENTON & Mme.Roseline DESCOUT
Organisation : ENSEA
Début du projet : ##########
Week : 1

	MISSIONS	DEBUT	FIN	STATUT	PROGRES
1	**DEFINITION DU PROBLEME**				
1.1	Spécifications	10/10/2025	17/10/2025	Complete	100%
2	**EQUIPEMENT/HARDWARE**				
2.2	CDCF + Choix des composants	17/10/2025	24/10/2025	Complete	100%
3	**PROGRAMMATION**				
3.1	Database	07/11/2025	07/11/2025	Complete	100%
3.2	Caméra	21/11/2025	28/11/2025	Complete	100%
3.3	Capteur ultrason	07/11/2025	07/11/2025	Complete	100%
3.4	Actionneurs	07/11/2025	14/11/2025	Complete	100%
3.5	IA	14/11/2025	28/11/2025	Complete	100%
5	**IMPLEMENTATION**				
5.1	Assemblage du montage final	05/12/2025	14/12/2025	Complete	100%
6	**TESTS**				
6.1	Test du projet	02/01/2026	09/01/2026	Complete	100%
6.2	Amélioration(s)	09/01/2026	20/10/2025	In Progress	20%
7	**FIN DU PROJET**				
7.1	Remise du rapport	09/01/2026	16/01/2026	Complete	100%

Figure 1 : Diagramme de Gantt du projet (planning et avancement).

En parallèle, le cahier des charges nous a permis de mettre noir sur blanc ce que notre système doit faire. La fonction principale est d'identifier les plastiques ciblés (PET, HDPE, PP, PS) rapidement et précisément. Ensuite, il faut éjecter au bon moment donc bien synchroniser la décision IA avec la détection réelle de l'objet devant les capteurs et l'activation des pistons. On a aussi ajouté des contraintes importantes qu'on retrouve en conditions réelles : affichage compréhensible pour l'opérateur, robustesse au flux, maintenabilité, résistance à l'environnement, et sécurité (éviter les décisions instables avec un seuil de confiance, par exemple).

Repère	Fonction	Critères d'appréciation	Niveau	Flexibilité / Paramètres
FP1	Doit être capable d'IDENTIFIER les déchets	Détection + classification des plastiques	-Types reconnus -Précision -Réactivité	- PET, HDPE, PP -> Type of Plastic Waste Dataset (kaggle) -Haute précision (classification) -Faible latence (détection)
FP2	Doit permettre d'ÉJECTER les déchets dans le bon compartiment	Projection dans le bon bac	-Réactivité -Puissance d'éjection -Fiabilité	-Capteurs ultrasons -Actionneur/Piston -Haut taux de réussite
FC1	Doit être en mesure d'INFORMER l'opérateur	User Interface live	-Lisibilité -Fluidité -Fiabilité du comptage	-Affichage temps réel fluide -Indicateurs clairs -Comptage fiable

FC2	Doit être en mesure de s'ADAPTER au flux de déchets	Cadence & densité	-Compatibilité ligne -Gestion chevauchements	-Adapté vitesses de tapis usuelles -Robuste aux objets chevauchés
FC3	Doit pouvoir ASSURER la maintenabilité	Sauvegardes & mises à jour	-Intégrité -Simplicité -Traçabilité	-Sauvegardes complètes -Mise à jour aisée (modèle) -Traçabilité bout-en-bout
FC4	Doit RÉSISTER à l'environnement	Poussière, humidité, service	-Protection -Continuité de service	-Enceintes protégées -Fonctionnement continu
FC5	Doit mettre en avant SÉCURITÉ & CONFORMITÉ	Sécurité machine & données	-Normes -Protections	-Conformité réglementaire -Carters, arrêts d'urgence -Protection des données
FC6	DONNÉES & IA	Dataset & amélioration continue	-Représentativité -Process	-Dataset diversifié -Pipeline de ré-entraînement -Mesures qualité
FC7	KPI, ESSAIS & RÉCEPTION	Vérification / Validation et critères	-Qualité IA -Performance système -Disponibilité	-Précision élevée -Latence bout-en-bout faible -Taux d'éjection élevé -Disponibilité élevée
FC8	INSTALLATION & UTILITÉS	Contraintes site	-Implantation -Énergies & fluides	-Adapté contraintes locales -Alimentation

Tableau 1 : Extrait du cahier des charges (fonctions FP/FC et critères).

Finalement, ces deux éléments nous ont servi de cadre tout le long : le Gantt pour avancer proprement, et le cahier des charges pour rester cohérents avec nos objectifs et nos critères de validation.

1.Contexte, Analyse du Besoin et Solutions Technologiques

1.1 Analyse de l'existant et limites

Notre analyse s'appuie sur le fonctionnement du centre de tri Cyrène à Triel-sur-Seine, qui nous sert de référence, bien que chaque centre possède leur propre configuration et son propre niveau d'automatisation. Le site Cyrène traite principalement les flux issus du bac jaune (emballages/papiers) et a trié 10 641 tonnes d'emballages en 2023 sur le périmètre Valoseine [1]. De manière générale, on retrouve toutefois une logique séquentielle commune : les déchets sont acheminés sur convoyeur, séparés par taille via un trommel, triés par forme (corps plats / corps creux), puis débarrassés des métaux ferreux, afin de préparer le flux avant la séparation matière.

Malgré cette chaîne déjà très mécanisée, le processus présente une limite majeure : il se termine presque systématiquement par une phase de tri manuel en cabine (tri-contrôle) pour corriger les erreurs résiduelles des machines. En effet, le tri automatique ne garantit pas une précision parfaite en conditions réelles, et certains déchets finissent

par passer au travers des “mailles du filet”, ce qui impose une correction humaine pour maintenir la qualité des flux sortants.

Le cœur technologique de cette automatisation reste le tri optique NIR, qui structure une grande partie du tri matière. Dans la pratique, le flux n’est pas séparé en une seule étape : les plastiques sont traités “par catégories”. Une machine est configurée pour sélectionner une résine cible (par exemple PET, puis plus loin PP, etc.) ; le NIR détecte la matière recherchée et la sort du flux, tandis que le reste continue sur une autre voie et sera repris plus loin par d’autres trieurs réglés sur une autre matière. Ce fonctionnement explique pourquoi, à l’échelle de la ligne, on a l’impression que “les plastiques tournent en rond” jusqu’à ce que chaque catégorie ait été extraite [2].

Sur le plan technique, le tri optique repose sur une analyse NIR–VIS réalisée en quelques millisecondes, comparée à des spectres de référence présents dans une base de données : la composition est déterminée à partir du spectre mesuré, puis l’emballage est éjecté vers une goulotte dédiée, généralement par air comprimé [2]. Toutefois, même si le principe est performant, les résultats dépendent fortement des conditions de présentation sur convoyeur (chevauchement, orientation, vitesse, état des déchets) et des propriétés des emballages, ce qui explique qu’une partie des erreurs subsiste et doive ensuite être corrigée manuellement [2].

Cette dépendance à l’intervention humaine engendre alors des problématiques critiques : une pénibilité importante (fatigue, répétitivité, contraintes physiques), mais aussi une difficulté croissante à recruter dans un secteur globalement marqué par une tension sur l’emploi. À titre indicatif, l’enquête BMO 2025 indique qu’en Île-de-France, 41,9 % des projets de recrutement sont jugés difficiles [3].

Pour situer l’enjeu industriel, on peut enfin donner quelques ordres de grandeur sur les équipements cités. Le prix d’un trieur optique varie selon la technologie et la cadence, avec une fourchette typique annoncée entre 30 000 € et 200 000 € [4]. Concernant les équipements de séparation mécanique, un crible / précrible est annoncé avec un ordre de prix indicatif compris entre 80 000 € et 227 850 € [5]. À l’échelle d’un investissement global, une ligne de tri automatisée complète peut représenter un budget de l’ordre de 500 000 € [6].

1.2 La réponse technologique : pourquoi remplacer le tri NIR par une approche caméra + IA

L’idée de ce projet est de sortir d’une logique où l’identification matière repose uniquement sur une signature NIR, et de remplacer cette étape par un système basé sur une caméra RGB et un modèle de Deep Learning. Concrètement, au lieu de “chercher la

matière dans un spectre", on cherche à apprendre au modèle à reconnaître les plastiques directement à partir de leur apparence (forme, texture, brillance, étiquettes, déformations), comme le ferait un opérateur à l'œil. Cette approche est pertinente car la vision par ordinateur permet d'intégrer de la variabilité réelle (objets froissés, sales, partiellement visibles) et d'améliorer progressivement le tri via l'apprentissage.

Dans la littérature, on retrouve précisément cette logique : Bobulski et Kubanek expliquent que le tri manuel est coûteux et difficile, et que des méthodes basées sur l'image et l'IA peuvent permettre de sélectionner automatiquement les plastiques sur un convoyeur. Ils cadrent aussi très bien la cible du projet, en rappelant que les quatre plastiques dominants en déchets ménagers sont PET, HDPE (PE-HD), PP et PS, et qu'une séparation automatique de ces quatre catégories est un enjeu direct pour améliorer la valorisation. Leur travail vise justement une méthode de séparation en 4 classes (PS, PP, PE-HD, PET) et insiste sur l'applicabilité en contexte "tri" (plante de tri) et sur des dispositifs compacts (microcaméra + micro-ordinateur). [7]

Un deuxième argument important, surtout si l'on vise un système embarqué et réactif, c'est la contrainte de calcul. Beaucoup de modèles très performants sont lourds (beaucoup de paramètres), ce qui les rend plus compliqués à déployer en temps réel. L'article de Nahiduzzaman et al. met justement en avant la nécessité de modèles légers, avec peu de paramètres, afin de réduire la complexité et rendre le déploiement plus réaliste sur des environnements contraints. Ils expliquent clairement la logique "modèle compact → surcharge minimale", et donnent un ordre de grandeur concret (modèle autour du million de paramètres) tout en restant dans une démarche de tri automatisé et de réduction du besoin de main d'œuvre manuelle. [8]

Enfin, l'intérêt industriel de "caméra + IA" est aussi documenté par des travaux qui se placent directement dans un cadre proche du nôtre : du tri sur flux, avec détection et action mécanique. Une revue récente sur la classification de déchets en contexte industriel analyse justement la place des données RGB et NIR pour le machine learning appliqué au tri, et montre que la vision (RGB) fait partie des voies sérieuses étudiées pour le tri des plastiques, avec des limites identifiées et des besoins de données adaptés au terrain. [9] De manière plus opérationnelle, Wen et al. proposent un schéma de détection basé sur deep learning pour un système de tri de plastiques "par vision", ce qui valide l'idée qu'une approche caméra + modèle peut être pensée comme une brique centrale d'un système de tri automatisé. [10]

Dans notre cas, cela revient à remplacer l'étape NIR par une chaîne simple et lisible : la caméra observe le flux, le modèle IA assigne une classe (PET/HDPE/PP/PS), puis le système déclenche l'éjection au bon moment. L'objectif reste le même que le tri NIR

(séparer en flux matière), mais avec une logique où la décision est apprise et peut être améliorée au fil des données collectées.

2. Développement du système de tri

2.1 Architecture matérielle et principe de fonctionnement du système

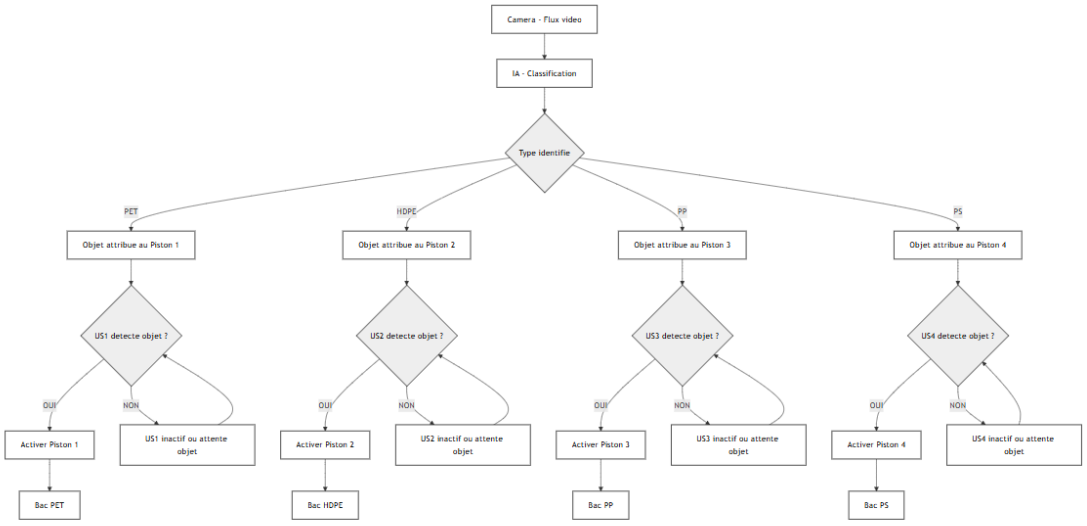


Figure 1 : Diagramme de flux du processus de tri automatisé par vision

La figure 1 présentée en 2.1 décrit l'architecture globale retenue pour automatiser le tri, en reprenant une logique proche de celle d'un trieur optique : un flux de déchets défile sur convoyeur, un module de détection identifie la nature de l'objet, puis un mécanisme d'éjection l'oriente vers le bac correspondant. Dans notre cas, la détection n'est plus assurée par un capteur NIR, mais par une caméra RGB associée à un modèle de Deep Learning.

Tout commence par l'acquisition vidéo au-dessus du convoyeur. Pour que la vision par ordinateur fonctionne, la stabilité de l'éclairage est non négociable. Une luminosité

changeante dégrade immédiatement la performance du modèle. Nous avons donc figé les conditions de prise de vue dans une zone contrôlée, afin d'assurer que les images restent comparables d'un passage à l'autre.

Les images capturées sont ensuite traitées par l'unité centrale du système, à savoir la Raspberry Pi, qui exécute le modèle IA en local. Le module de classification renvoie un type de plastique identifié parmi les classes visées (PET, HDPE, PP, PS), ainsi qu'un score de confiance. Cette étape correspond à la "décision matière" du système : on associe une classe à l'objet en mouvement afin de décider de l'action à effectuer ensuite, avec une sortie exploitable en temps réel.

Une fois la classe obtenue, l'objet est attribué à un piston. Le diagramme représente une architecture cible "un plastique → un piston", ce qui rend la stratégie de tri simple et lisible : PET vers piston 1, HDPE vers piston 2, PP vers piston 3, PS vers piston 4. Cette attribution n'active pas immédiatement l'éjection, car l'objet doit encore parcourir une distance entre la zone de capture caméra et la zone des actionneurs. Le point central de l'architecture est donc la synchronisation : l'objectif n'est pas d'éjecter au moment où l'objet est reconnu par la caméra, mais au moment où il arrive réellement devant le bon piston.

Pour garantir ce bon timing, chaque piston est associé à un capteur ultrason (US1 à US4). Le rôle de l'ultrason est de vérifier la présence de l'objet au niveau de l'éjection : tant que le capteur ne détecte rien dans la zone définie (seuil de distance), le piston reste inactif ou en attente ; dès que l'objet est détecté, le piston correspondant est activé et l'objet est dévié vers le bac associé. Le diagramme résume directement cette logique : "objet attribué au piston X", puis "USX détecte objet ?", puis "activer piston X" si la condition est vraie. Sur le plan technique, la mesure ultrason est basée sur un principe de temps de vol, c'est-à-dire la mesure du délai entre l'émission d'une onde et la réception de son écho, ce qui permet de calculer une distance et de déclencher une action mécanique au bon instant.

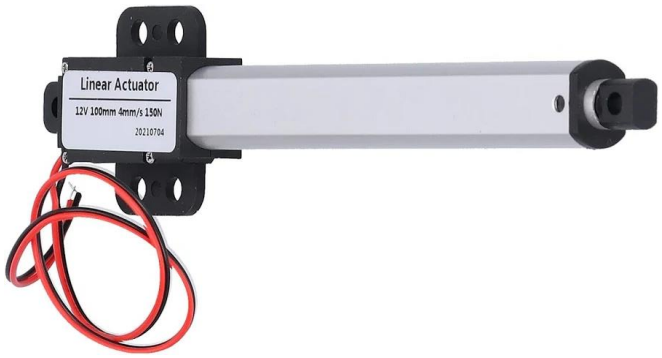
Enfin, cette architecture impose des choix de robustesse pour éviter les comportements erratiques. Un seuil de confiance minimal est nécessaire afin d'éviter d'envoyer trop de décisions lorsque la prédiction est incertaine, ce qui risquerait de saturer la logique d'attribution et de provoquer des actions non pertinentes. Dans la même logique, des temporisations simples (temps minimal entre deux actions, délais d'attente capteur) permettent de stabiliser le fonctionnement du système en conditions réelles.

L'ensemble forme une chaîne simple et lisible "caméra → IA → unité centrale (Raspberry Pi) → attribution → capteur de présence → actionneur", compatible avec un fonctionnement continu sur convoyeur et avec des contraintes de temps réel.

2.2 Critères de choix des matériels et composants retenus

Pour réaliser un prototype fonctionnel, nous avons sélectionné des composants accessibles (COTS - Commercial Off-The-Shelf) et compatibles avec une intégration embarquée. L'objectif était de constituer une chaîne complète "détection → calcul → synchronisation → action" sécurisée et adaptée aux contraintes de développement.

Système d'éjection



Vérins électriques (Actionneurs linéaires) Pour l'éjection, nous avons retenu des mini actionneurs linéaires 12 V (Réf. ACRM00185 / ACRZilla) offrant une course de 100 mm et une vitesse de déploiement de 150 mm/s. Bien que les vérins pneumatiques constituent le standard industriel pour leur rapidité, ils imposent une gestion complexe de l'air comprimé et présentent des risques accrus (pincements, haute pression) inadaptés à un contexte de prototypage rapide. La solution électrique 12 V s'est avérée le meilleur compromis puisqu'elle permet une alimentation directe, une commande simplifiée (inversion de polarité) et un coût maîtrisé (~30€ HT/unité) rendant réaliste la multiplication des voies de tri.

Synchronisation et Localisation



Pour garantir que le piston ne s'active qu'en présence physique de l'objet, nous avons sélectionné des Télémètre à ultrasons Grove 101020010. Nous ne sommes pas partis sur des capteurs infrarouges (IR) car ces derniers présentent énormément de lacunes sur les plastiques transparents ou noirs. Les capteurs ultrasons fonctionnent par écho sonore ce qui signifie que la détection n’est pas impactée par la couleur ou la transparence du matériau tout en offrant une précision millimétrique dans un intervalle de [2; 400 cm].

Unité de calcul embarquée



Le cœur du système repose sur une Raspberry Pi 5 (version 8 Go). Ce choix se justifie par le besoin de puissance pour l’implémentation de l'IA. Contrairement aux microcontrôleurs classiques, la Pi 5 dispose d'un couple CPU/GPU suffisant pour exécuter l'inférence du modèle YOLOv8 en temps réel avec une faible latence. La version 8 Go de RAM est spécifiquement retenue pour éviter les goulots d'étranglement mémoire

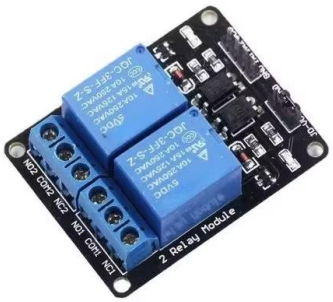
lors du chargement du modèle. De plus, ses GPIOs permettent un pilotage des périphériques sans l'utilisation de carte externe.

Acquisition Visuelle



L'acquisition d'images est assurée par le Raspberry Pi Camera Module 3. Doté du capteur Sony IMX708 (12 MP) et d'un autofocus, la caméra présente une haute résolution qui s'avère indispensable pour distinguer les caractéristiques fines des emballages (étiquettes, textures). Il est important de noter que ce choix matériel est indissociable des conditions d'intégration : la fiabilité de la classification IA dépend directement de la stabilité lumineuse. Le module caméra est donc intégré dans une zone à éclairement "contrôlé" pour limiter les zones sombres et des reflets non voulus.

Interface de Puissance



Pour assurer l'interface entre la logique de commande (Raspberry Pi en 3.3V/5V) et la puissance des actionneurs (12V), nous utilisons le module relais OPENME114. Ce composant est idéal pour piloter des dispositifs externes dont la tension/courant sont élevés. Ses optocoupleurs permettent de transmettre le signal électrique vers les pistons de manière fiable.

Base de données utilisée pour l'apprentissage du modèle IA

Pour entraîner notre modèle de classification, nous avons retenu une base de données d'images issue de la plateforme Kaggle ("Type of Plastic Waste", A.R. Hakim) , structurée en quatre classes correspondant aux plastiques visés par le projet : PET, HDPE, PP et PS. La base représente environ 7 Go de données, ce qui est cohérent avec un apprentissage sur images réelles tout en restant manipulable sur un environnement de développement.

Un point important est que cette base ne contient pas uniquement des "objets parfaits" : on y trouve des plastiques dans des états variés, notamment des objets écrasés, avec des variations d'apparence (atténuation de couleur, brillance, reflets), ainsi que des prises de vue sous plusieurs angles. Cette diversité est essentielle car elle se rapproche des conditions réelles sur convoyeur, où les déchets ne se présentent jamais de manière parfaitement standardisée.

La répartition des images entre l'ensemble d'entraînement (*train*) et l'ensemble de validation (*val*) est la suivante :

Classe Plastique	**Total Images**	**Entraînement (70%)**	**Validation (15%)**	**Test (15%)**
HDPE	**3 188**	2 231	478	479
PET	**3 142**	2 199	471	472
PP	**2 429**	1 700	364	365
PS	**2 493**	1 745	373	375
TOTAL	**11 252**	**7 875**	**1 686**	**1 691**

Cette distribution montre que les quatre classes sont bien représentées, avec une base globalement équilibrée, même si HDPE/PET sont légèrement plus présents que PP/PS. Cette étape est importante car elle permet d'expliquer pourquoi le modèle peut apprendre à généraliser : il voit des exemples réalistes (déformations, angles, variations visuelles) au lieu d'apprendre uniquement des "images propres".

2.3 Constitution du Dataset et Entraînement du Modèle IA

Le cœur de notre système de tri repose sur un algorithme de Deep Learning capable d'identifier les plastiques (HDPE, PET, PP, PS) à partir d'images issues d'un flux vidéo. Cette section présente la méthodologie mise en place, depuis la préparation des données jusqu'à l'entraînement du modèle, afin d'obtenir une première base fiable avant le déploiement sur le système embarqué.

2.3.1 Stratégie d'annotation automatisée (supervision faible)

La première étape a consisté à constituer une base d'apprentissage exploitable. Nous disposions d'un jeu d'entraînement de 11 252 images, déjà organisé par classes. Une annotation manuelle complète (dessin précis des boîtes englobantes pour chaque image) aurait été trop coûteuse en temps dans le cadre du projet. Nous avons donc mis en place une stratégie d'annotation automatisée, basée sur des hypothèses simples mais efficaces pour générer rapidement un dataset compatible avec YOLO.

Un script Python a été développé afin de générer automatiquement les fichiers de labels (`.txt`) au format YOLO. Cette génération repose sur deux principes :

L'extraction sémantique (la classe) : l'identité du plastique est directement déduite de l'arborescence des fichiers. Le script associe le nom du dossier parent à un identifiant numérique (par exemple : dossier PET → classe correspondante).

L'extraction géométrique (la position) : nous avons appliqué une heuristique de centrage. En considérant que l'objet d'intérêt est le sujet principal de la photo, nous générons une bounding box artificielle centrée (x = 0,5 ; y = 0,5) couvrant environ 80 % de la surface de l'image.

Cette approche correspond à une forme de supervision faible : elle ne fournit pas une localisation exacte, mais elle permet de transformer instantanément une base "classification" en un problème de "détection" exploitable par YOLO, et donc de valider rapidement la faisabilité de l'approche.

2.3.2 Architecture retenue et apprentissage par transfert

Pour la modélisation, nous avons choisi l'architecture **YOLOv8 (You Only Look Once)**, connue pour son compromis entre rapidité et précision, ce qui correspond aux contraintes du tri en temps réel. Nous avons utilisé la variante yolov8s (Small**)** afin de conserver un modèle suffisamment léger et déployable.

Pour optimiser les performances et ce, malgré un dataset spécifique, nous avons utilisé le Transfer Learning (apprentissage par transfert). Le modèle a été initialisé à partir de poids pré-entraînés sur un dataset généraliste, ce qui lui permet de disposer dès le départ de filtres capables d'extraire des caractéristiques visuelles de base (bords, textures, contrastes). Nous avons ensuite réalisé un fine-tuning sur nos quatre classes (HDPE, PET, PP, PS), via un entraînement sur Google Colab avec un GPU, afin d'accélérer l'apprentissage.

2.3.3 Hyperparamètres et configuration d'entraînement

L'entraînement du modèle a été réalisé à partir de l'architecture **YOLOv8s**, initialisée avec des poids pré-entraînés afin d'exploiter l'apprentissage par transfert. Nous avons configuré l'apprentissage sur 20 époques, avec une taille d'image fixée à 640×640 pixels et un batch size de 16. L'exécution a été effectuée sur Google Colab avec accélération GPU (Tesla T4), ce qui nous a permis de réduire le temps de calcul et de suivre les métriques de performance à chaque époque.

L'objectif à ce stade n'était pas uniquement d'optimiser une précision maximale, mais surtout de valider une chaîne complète : génération des labels, apprentissage du modèle, puis capacité à produire une prédiction exploitable dans un contexte temps réel. Les paramètres retenus représentent donc un compromis entre simplicité, stabilité de convergence et temps d'entraînement compatible avec le cadre du projet.

2.3.4 Résultats obtenus et analyse des performances

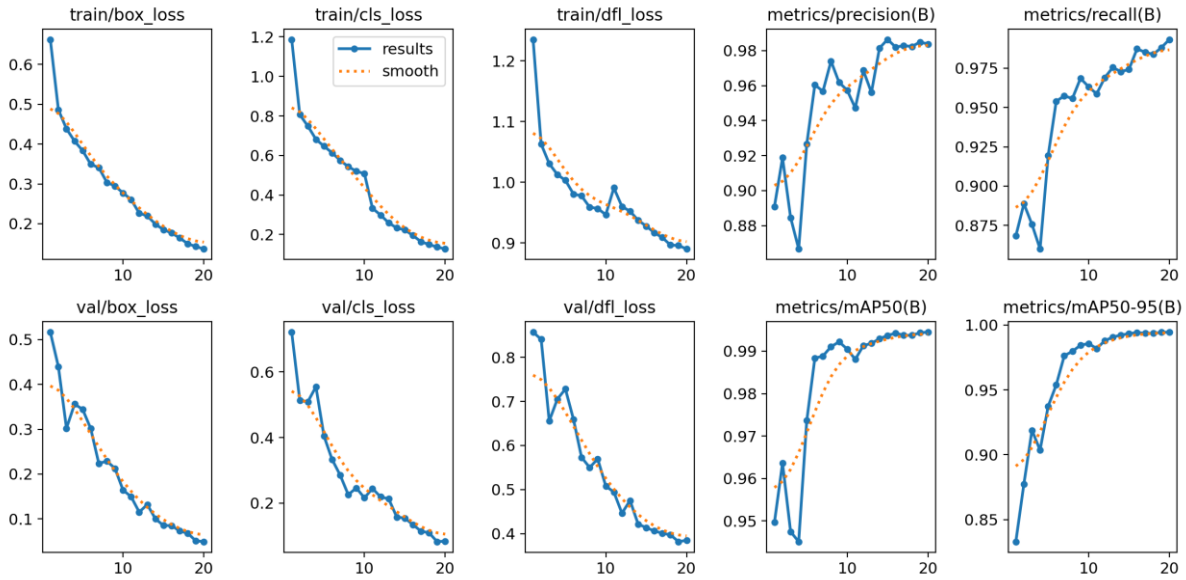


Figure 2 : Évolution des métriques d'apprentissage (Pertes, Précision, Rappel et mAP) sur 20 époques.

Les résultats montrent une convergence rapide et stable. Les courbes d'apprentissage présentées en figure 2 mettent en évidence une diminution continue des pertes d'entraînement et de validation (box loss, cls loss et dfl loss), associée à une progression régulière des métriques (précision, rappel et mAP). On observe une stabilisation des performances sur les dernières époques, ce qui indique que le modèle atteint un régime de convergence satisfaisant dans notre configuration.

À l'issue des 20 époques, l'évaluation sur l'ensemble de validation donne des performances globales élevées, avec une précision proche de 0,984, un rappel proche de 0,993, ainsi qu'un mAP@05 d'environ 0,994. Ces valeurs confirment que le modèle est capable d'identifier correctement les quatre classes de plastiques ciblées, dans les conditions de notre base de données et avec la stratégie d'annotation retenue.

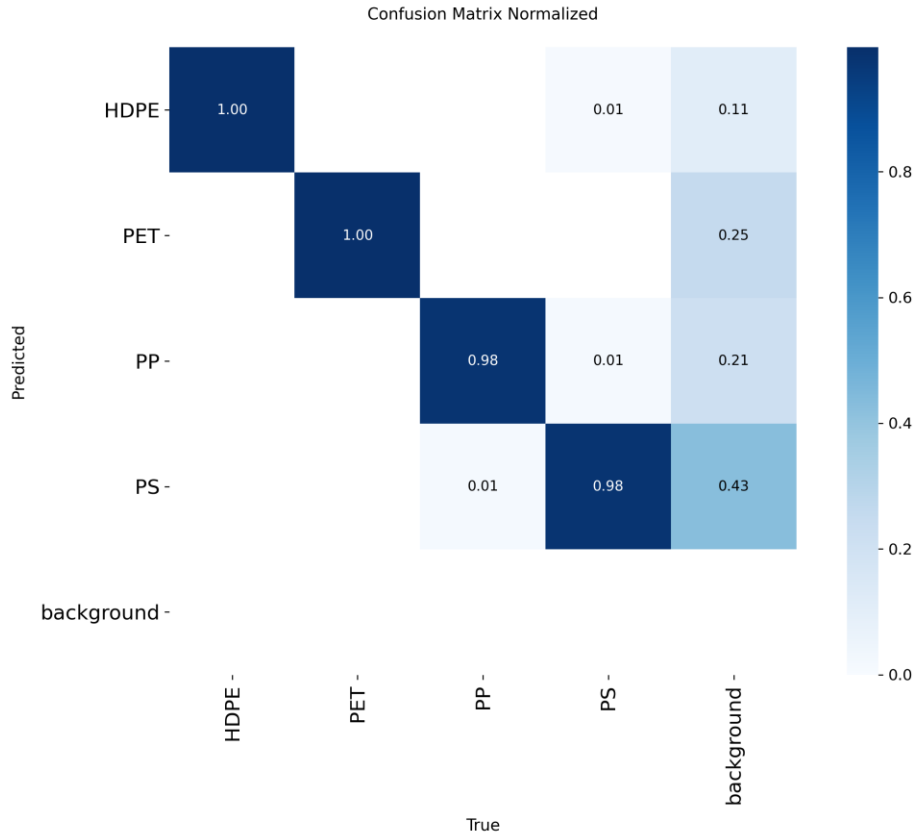


Figure 3 : Matrice de confusion normalisée illustrant la précision de classification par type de plastique.

La matrice de confusion (Figure 3) est cohérente avec la composition du dataset, les classes les plus représentées dans la base (PET et HDPE) obtiennent des scores très proches de 1 ce qui est logique car le modèle a vu davantage de variations de ces plastiques pendant l'apprentissage. Les classes PP et PS restent également très bien reconnues mais présentent une performance légèrement inférieure (environ 0.98). Cette différence s'explique par plusieurs facteurs. D'une part, PP et PS sont un peu moins présents dans la base ce qui réduit mécaniquement la diversité des exemples vus à l'entraînement. D'autre part, ces 2 familles peuvent présenter des formes et textures visuellement proches dans notre dataset (emballages écrasés, reflets, surfaces brillantes, étiquettes) créant des cas ambigus au moment de la classification.

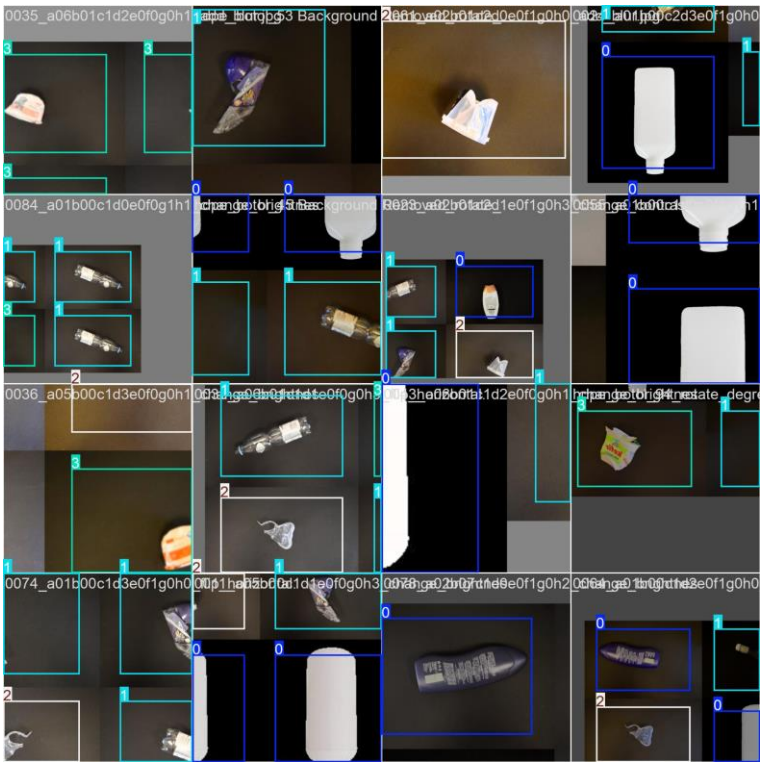


Figure 4 : Exemples de prédictions sur le jeu de validation : visualisation des Bounding Boxes et des confiances associées.

Cette réussite se confirme visuellement en Figure 4. Le modèle parvient à classifier la majorité des objets, peu importe leur état (écrasés, déformés) ou leur orientation . Les rares erreurs observées apparaissent surtout sur des images atypiques, par exemple lorsque l'objet est fortement déformé, partiellement masqué, ou lorsque les conditions de lumière accentuent les reflets.

Et enfin, les temps d'exécution mesurés lors de la validation indiquent une inférence rapide sur GPU avec un ordre de grandeur de quelques ms par image. Cela confirme la faisabilité d'un traitement en temps réel et justifie l'utilisation de ce modèle comme base de référence avant l'intégration embarquée et les essais sur convoyeur.

3. Implémentation embarquée et validation expérimentale

3.1 Architecture logicielle

3.1.1 Module Caméra et Classification IA

Le module `yolo_cam.py` correspond à la partie "vision" du système. C'est lui qui permet au prototype de voir ce qui passe sur le convoyeur et de transformer une image en information exploitable par la suite du programme. En pratique, l'objectif est simple : identifier le type de plastique présent sur le tapis (HDPE, PET, PP ou PS) et fournir en même temps un niveau de confiance, afin que la commande mécanique ne parte pas sur une décision incertaine.

Le programme commence par mettre en place une acquisition vidéo continue à l'aide de la bibliothèque Picamera2, qui est particulièrement adaptée au Raspberry Pi et à son interface CSI. Le flux est configuré en 640×480 au format BGR, ce qui permet de travailler directement avec OpenCV sans conversions supplémentaires. Ce point est important car, dans un système temps réel, chaque conversion inutile peut ajouter de la latence et rendre la boucle plus lente. Ici, l'image capturée est directement utilisable, à la fois pour l'analyse et pour l'affichage pendant les tests.

À chaque image (ou à intervalles réguliers selon la cadence choisie), l'IA est appelée pour produire une classification. Contrairement à l'approche en détection utilisée pendant la phase d'entraînement, on utilise ici un modèle en mode classification chargé depuis `best.pt`. Le principe est que l'image complète est analysée, puis le modèle renvoie une probabilité pour chacune des classes. L'image est redimensionnée en 224×224 pixels pour l'inférence, ce qui correspond à une taille standard en classification et permet de limiter la charge de calcul tout en conservant suffisamment d'informations visuelles. Même si la résolution est réduite, le modèle garde accès aux indices globaux qui font la différence entre matériaux, comme l'aspect de la surface, la texture, la brillance, la transparence ou encore certains détails d'étiquette.

Le résultat obtenu ne se base pas seulement sur "oui/non" mais une distribution de probabilités. Le programme récupère donc la classe la plus probable ainsi que son score associé. L'ordre des classes est fixé et cohérent avec celui utilisé pendant l'entraînement garantissant que l'index retourné correspond bien au bon plastique. C'est un détail qui peut sembler simple mais il est crucial, si l'ordre était faux, on pourrait déclencher le mauvais piston même avec une bonne confiance ce qui reviendrait à mal trier.

Ensuite, pour éviter les décisions instables, on ajoute une règle de robustesse basée sur un seuil minimal de confiance. Tant que la confiance reste sous 0.6, le système ne “force” pas une catégorie et renvoie volontairement un label “unknown”. Ce choix est volontairement prudent parce qu’en tri, une mauvaise décision a un impact direct puisqu’on pollue le mauvais bac, on dégrade la qualité de la fraction et on perd l’intérêt du système. Ici, on préfère donc ne pas trier plutôt que trier faux. Ce filtrage joue aussi un rôle pratique puisqu'il évite d’envoyer au programme principal des prédictions qui changent sans arrêt quand l’image est mauvaise (flou, angle défavorable, objet partiellement visible, reflets, éclairage instable). En réalité, c’est exactement ce qu’on recherche sur une chaîne à savoir des décisions stables, pas une IA qui “hésite” à chaque frame.

Enfin, le module produit aussi un retour visuel sur l’image. Le label et le score s’affichent directement sur la frame, en vert si une classe est reconnue et en rouge si le système est incertain. Cette visualisation est très utile pendant les essais car elle permet de comprendre immédiatement si la caméra voit correctement l’objet, si la prédiction est cohérente et surtout pourquoi la confiance baisse dans certains cas. Par exemple, on repère tout de suite l’influence d’un reflet, d’un plastique écrasé, d’une ombre ou d’un objet mal positionné sur le tapis.

Au final, ce module fournit une information simple et directement exploitable à savoir un label, une confiance et une image annotée. C’est cette sortie qui sert ensuite à alimenter la logique de tri en décidant s’il faut prendre en compte l’objet, dans quelle catégorie il doit aller, ou au contraire l’ignorer si la décision est jugée trop risquée.

3.1.2 Contrôle des pistons

OBJECTIF

L’objectif de cette partie est de mettre en œuvre le contrôle de pistons pour le tri automatisé des déchets plastiques.

MISSIONS PRINCIPALES

Le travail a été réduit en 3 étapes :

-Enregistrement du type de plastique dans un tableau

-Mesure de distance

-Contrôle des pistons

ENREGISTREMENT DU TYPE DE PLASTIQUE DANS UN TABLEAU

OBJECTIF

Stocker les différents types de plastique identifiés et les traiter séquentiellement.

MISE EN ŒUVRE

Pour gérer le flux de déchets identifiés par la caméra et l'IA, le programme s'appuie sur une structure de données organisée selon le principe FIFO qui consiste à garantir l'ordre chronologique du tri, cela signifie que le 1er objet identifié par la caméra est impérativement le 1er traité par les ultrasons/pistons ce qui assure qu'aucun objet n'est sauté ou trié dans le désordre.

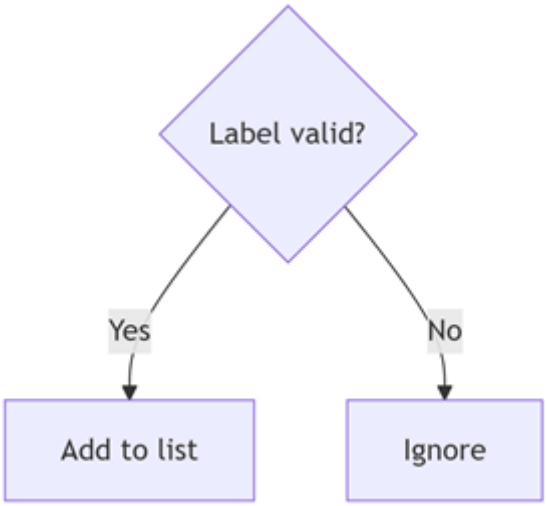


Figure 5 : Ajout du label dans la liste

Comme dit précédemment, une liste de type FIFO a été créé. Une fonction spécifique se charge d'ajouter chaque type identifié à la fin de cette liste. Un filtre a été mis en place pour garantir la fiabilité du système, dans d'autres termes, cela signifie que si l'identification est incertaine ou marquée comme inconnue, dans ce cas, l'information est ignorée et n'entre pas dans la file d'attente.

Ainsi, le traitement s'effectue ensuite dans la boucle principale du programme, le système extrait le 1er élément de la liste pour le traiter et tant que cet objet n'a pas été trié, le système ne passe pas au suivant.

RESULTATS

```
Label add: HDPE
File now: ['PET', 'PET', 'PET', 'PET', 'PET', 'PET', 'PET', 'PET', 'PET', 'PET', 'HDPE', 'HDPE', 'HDPE', 'HDPE', 'HDPE', 'HDPE', 'HDPE']
Label add: HDPE
File now: ['PET', 'PET', 'PET', 'PET', 'PET', 'PET', 'PET', 'PET', 'PET', 'PET', 'HDPE', 'HDPE', 'HDPE', 'HDPE', 'HDPE', 'HDPE', 'HDPE']
```

Figure 6 : Liste contenant les labels

Grâce à cette logique, le programme permet de mémoriser les objets identifiés en amont et de respecter l'ordre de passage assurant une synchronisation parfaite entre l'étape d'identification et l'activation mécanique des pistons qui sera expliqué par la suite.

MESURE DE DISTANCES

OBJECTIF

Mesurer la distance en temps réel afin de détecter la présence physique de l'objet devant les pistons.

MISE EN ŒUVRE

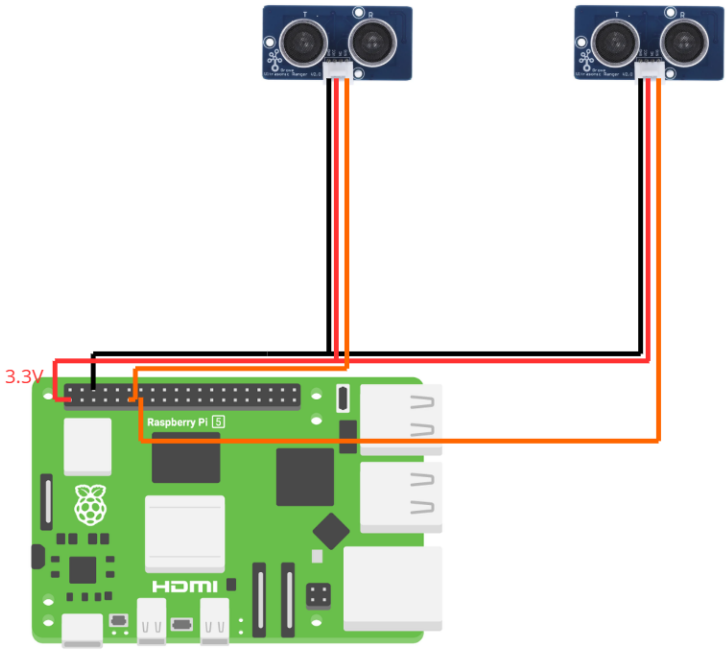


Figure 7 : Câblage des ultrasons

La détection repose sur l'utilisation d'un capteur à ultrason placé à proximité de chaque piston.

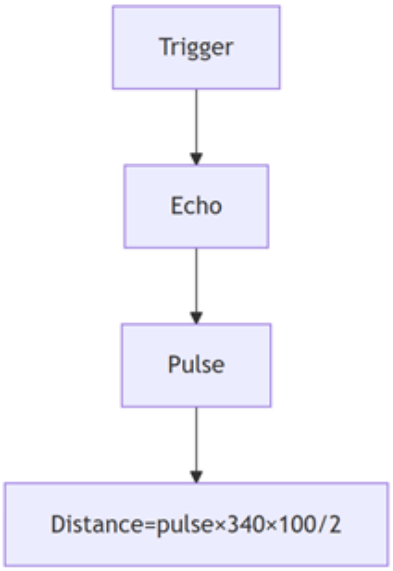


Figure : Mesure de la distance

Le Trigger correspond au signal émis, Echo correspond à la réception de ce signal envoyé et Pulse correspond au temps d'émission de ces derniers.

Le système émet dans un 1er temps une impulsion et mesure le temps que ce dernier met pour faire l'allée retour après avoir rebondi sur l'objet. La distance entre l'emplacement d'un capteur ultrason et d'un objet est calculée à l'aide de la formule suivante :

$$\text{Distance} = \frac{durée \cdot 340 \cdot 100}{2}$$

Durée correspond au temps mesuré entre l'émission et la réception de l'onde, 340 est la valeur de la vitesse du son dans l'air (m/s), 100 est la conversion de m vers cm et 2 correspond au son qui fait un aller-retour.

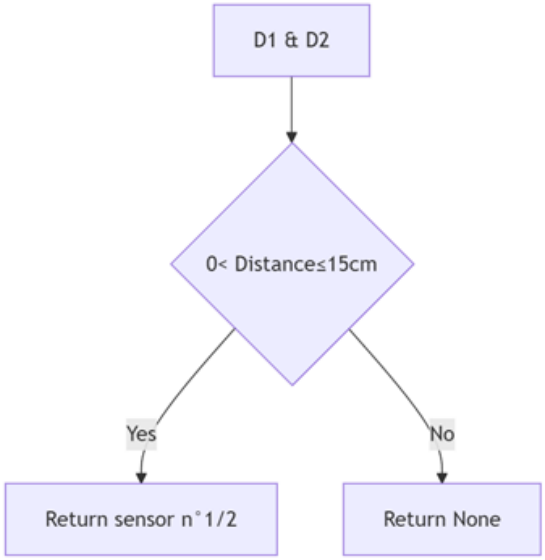


Figure 8 : Etat selon le capteur

D1 correspond à la distance mesurée par le capteur à ultrason n°1 et D2 correspond à la distance mesurée par le capteur ultrason n°2. Le programme mesure en permanence la distance.

Selon la distance de seuil prédéfinie, le programme considère qu'un objet est présent devant le piston et retourne un état selon le capteur associé.

RESULTATS

```
D1: 8.1cm, D2: 23.8cm
1 open
(1)forPET
D1: 6.1cm, D2: 24.3cm
1 open
(1)forPET
D1: 5.9cm, D2: 24.7cm
1 open
(1)forPET
D1: 10.8cm, D2: 23.8cm
1 open
(1)forPET
D1: 22.5cm, D2: 5.9cm
```

Figure 9: Obtention des mesures de distances

D'après la Figure, les capteurs retournent bien une valeur à chaque fois permettant de servir de conditions pour piloter les pistons.

CONTROLE DES PISTONS

OBJECTIF

Contrôler les pistons afin qu'ils puissent éjecter l'objet dans le bon compartiment.

MISE EN ŒUVRE

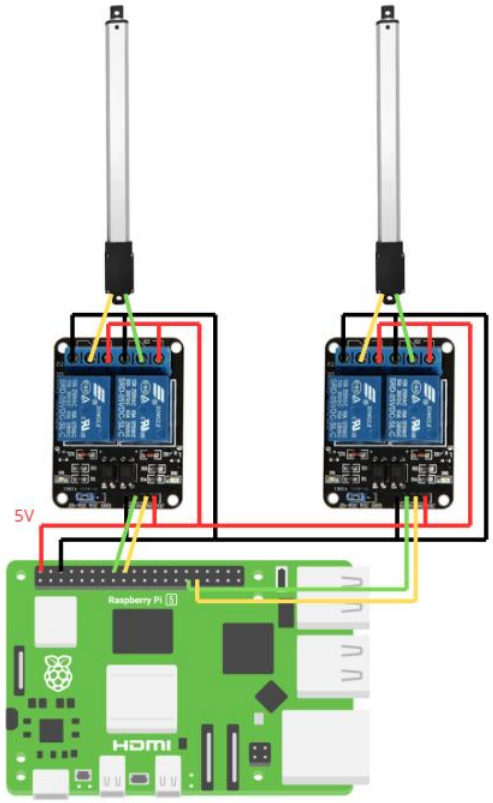


Figure 10 : Câblage des pistons

Comme dit précédemment, les modules permettent d'alimenter correctement les pistons mais aussi de les contrôler.

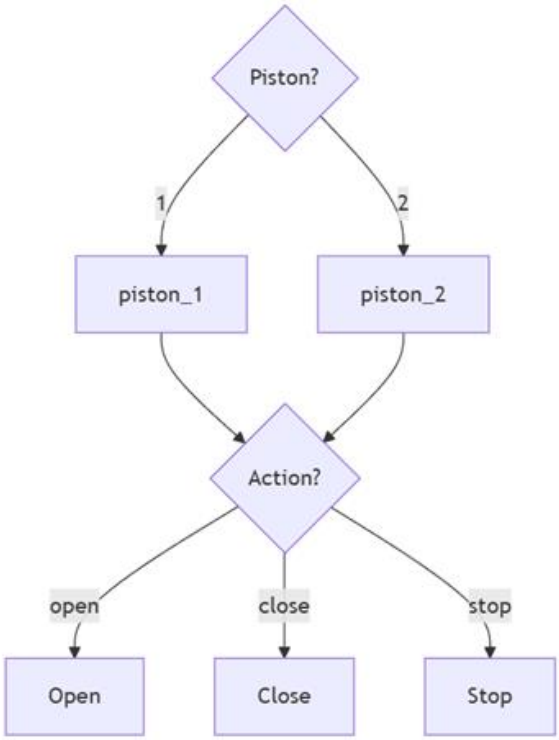


Figure 11 : Description du contrôle des pistons

Pour ouvrir le piston, le système envoie un signal électrique vers la broche d'ouverture tandis que la broche de fermeture reste sans tension. Même procédé pour la fermeture, le système n'envoie plus vers la broche d'ouverture mais envoie vers la broche de fermeture. Auquel cas, rien n'est activé et le piston reste fermé.

Le programme compare le type de plastique attendu issue de la liste avec le capteur qui vient de se déclencher.

Une fois l'ordre validé, une séquence temporisée s'exécute suivant la forme suivante :

Déploiement du piston -> pause pour assurer l'éjection -> rétraction du piston

Ce programme tourne en boucle cela jusqu'à ce que plus aucun label ne soit présente dans la liste.

3.1.2 Mise en place du système global

OBJECTIF

L'objectif est de rassembler l'intégralité des programmes que ce soit pour l'identification des plastiques à l'aide de la caméra ainsi que de la partie contrôle des pistons.

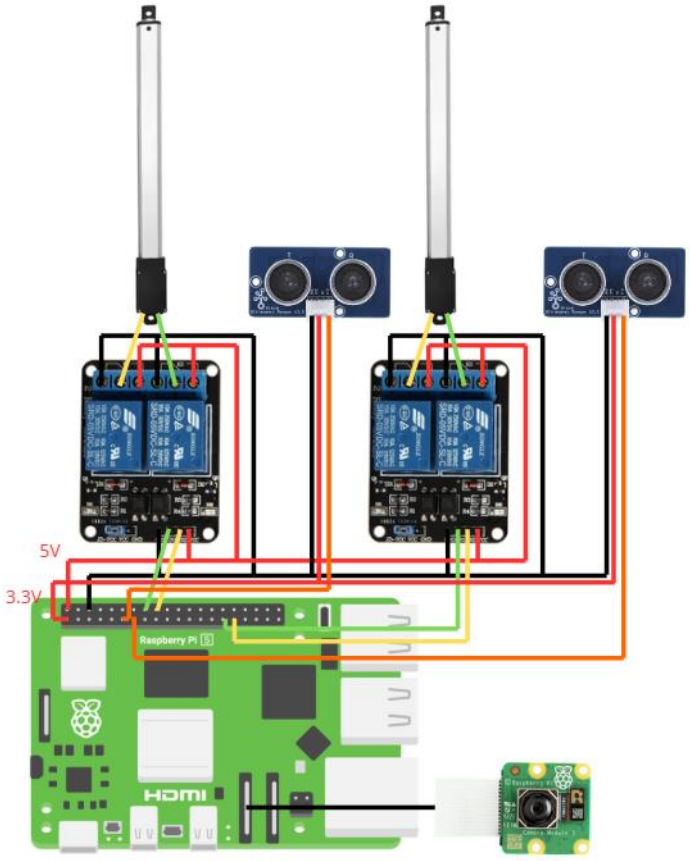


Figure 12 : Montage complet

MISSIONS PRINCIPALES

Le travail a été divisé en 3 étapes :

-INITIALISATION ET PARAMETRAGE

-GESTION DE L'IA

-PRISE DE DECISION ET SYNCHRONISATION

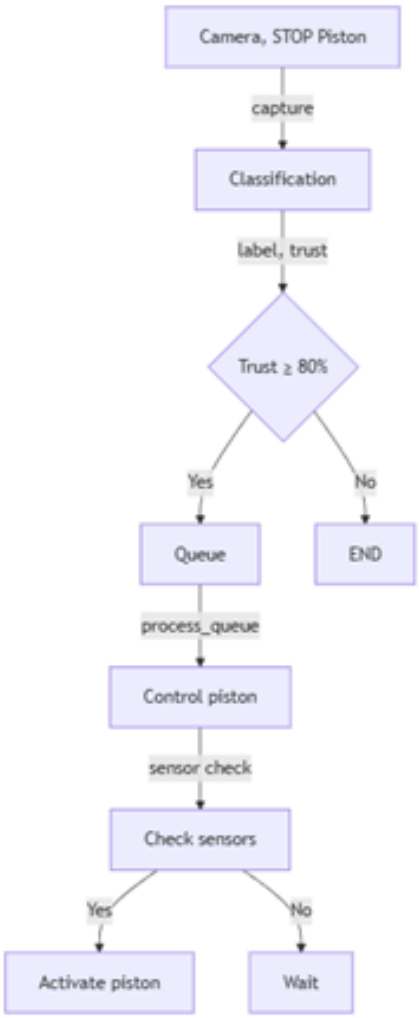


Figure 13 : Programme final

INITIALISATION ET PARAMETRAGE

OBJECTIF

L'objectif est de préparer le système pour garantir un démarrage sécurisé et définir les règles de réactivité avant le lancement de la chaîne de tri.

MISE EN ŒUVRE

Dès le lancement du programme, les pistons sont forcés en position de fermeture pour s'assurer le système démarre dans de bonnes conditions. Ensuite la caméra est initialisée pour la capture de flux vidéo.

Le programme définit également des constantes essentielles pour la stabilité du tri avec notamment avec un seuil de confiance fixe afin de s'assurer que le système est configuré pour n'agir que si l'IA est sûre de la classification à plus de 80%.

GESTION DE L'IA

OBJECTIF

L'objectif est de regarder les objets passer devant la caméra sans compromettre les performances de la carte.

MISE EN ŒUVRE

Mine de rien, l'analyse d'image nécessite énormément de ressources à la carte, au point que la caméra présente du délai et des lags pour afficher un retour image. Pour éviter ces problèmes, le programme décortique l'image à un court intervalle de temps (0.5 sec) afin de laisser assez de temps nécessaire pour associer un label à l'objet visualisé.

PRISE DE DECISION ET SYNCHRONISATION

OBJECTIF

L'objectif est de labeliser les objets détectés pour décider du tri et éviter les erreurs.

MISE EN ŒUVRE

Cette prise de décision réalise 2 vérifications avant d'agir. Dans un 1er temps, le programme s'assure que l'IA détecte un type de plastique à plus de 80% et dans un 2nd temps, le programme attend un peu pour s'assurer de ne pas compter le même objet une 2nde fois.

Si ces vérifications sont validées, les informations sont envoyées afin de servir de conditions pour commander les pistons.

3.2 Réalisation de la maquette et premiers tests du système

Avant de commencer l'assemblage final, on a décidé de réaliser une maquette simple faite à partir de planches de récupération. L'idée était d'avoir quelque chose de concret rapidement pour valider le placement des composants. Vérifier que tout "rentre" correctement et surtout pouvoir tester la logique complète caméra → IA → capteur → actionneur sans attendre une structure définitive. On a peint l'ensemble en blanc, parce que ça aide beaucoup pour la vision rendant ainsi le fond plus uniforme, moins de textures "encombrantes" et ça évite que la couleur du support influence l'image ou crée des contrastes bizarres. En pratique, ça nous a aussi permis d'avoir des images plus propres côté caméra avec moins d'ombres marquées et moins de reflets "crades" qui peuvent perturber la confiance du modèle.

Lors de la préparation de la maquette, on a commencé par prendre les dimensions exactes des composants à intégrer notamment le diamètre des capteurs ultrasons et l'encombrement des vérins. Ces informations sont disponibles directement dans les datasheets ce qui nous a permis de percer les trous au bon format sans approximation. On a donc réalisé les ouvertures sur la façade pour les télémètres et les passages nécessaires pour la partie mécanique des pistons. On s'est rendu compte que cette étape est importante parce qu'un trou mal dimensionné te force à bricoler derrière et ça finit souvent par créer du jeu mécanique, des capteurs pas bien alignés ou des vibrations… et ça se ressent sur la répétabilité des tests.

Pour la caméra, on a fait un support en angle que l'on a percée pour que l'optique puisse passer correctement et que la caméra soit stable, bien alignée et surtout figée. C'est un point clé parce que si l'angle ou la hauteur de la caméra change même légèrement, le rendu des images change aussi. Et derrière, comme le modèle est sensible à l'apparence (angles, reflets, zones surexposées), ça peut faire chuter la confiance et donner des prédictions moins stables d'un test à l'autre.

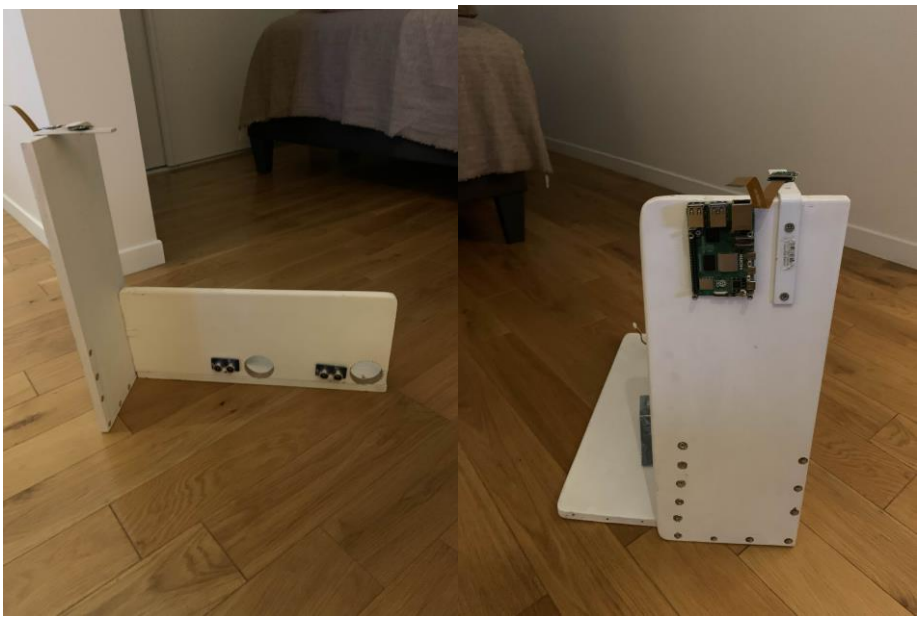


Figure 14 & 15 : Photos du bois blanc et de la Raspberry vissée

Une fois les trous faits, on a positionné les éléments sur la structure. Sur les Figures 14-15, on voit bien que les composants ont été vissés et “fixés” pour garder une maquette rigide. On a choisi de mettre la Raspberry Pi en haut à droite. Ce n’était pas juste un placement au hasard, cela est dû au fait que le câble de la caméra est court, il fallait que la carte soit proche pour éviter de forcer sur la nappe, limiter les risques de faux contacts et garder un montage propre. Ce placement en hauteur a aussi un avantage en phase de test puisqu’il ça protège un peu l’électronique quand on manipule les objets et ça libère la zone basse pour les actionneurs, les capteurs et tout ce qui bouge.

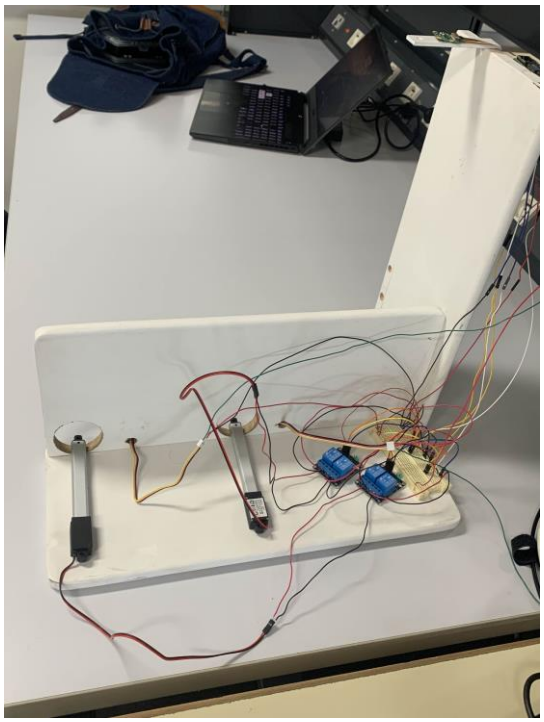


Figure 16 : Photo du câblage

Après cette phase de placement mécanique, on est passé au câblage sur la maquette. L'objectif ici était surtout de valider que tout le système est réellement pilotable avec la lecture des ultrasons, commande des relais, alimentation des vérins et réaction correcte au moment du déclenchement. La maquette câblée apparaît sur la Figure 16. Pour être franc, ce n'est pas le câblage "propre" qu'on garderait sur une version finale mais ce n'était pas la priorité à ce stade. On était dans une logique prototype qui est de faire fonctionner la chaîne complète, voir si les capteurs répondent correctement, vérifier que les vérins se déclenchent quand il faut et identifier les points faibles. Ici l'idée est surtout de montrer que cette maquette sert de support réel pour intégrer le système complet.

Ensuite, on a commencé les tests et assez vite, on s'est rendu compte d'un point important, le modèle IA initial (YOLO small) et l'exécution en même temps des programmes caméra + pistons sur la Raspberry Pi avaient du mal à tourner correctement. On observait de la latence, parfois une impression de "décrochage" et ça rendait les essais moins stables. Du coup, on a adapté la solution en passant sur un modèle plus léger qui est YOLO nano en classification (cls). On perd potentiellement un peu de capacité mais on gagne en fluidité et surtout en stabilité ce qui est crucial pour un système temps réel. L'objectif à ce stade n'était pas d'avoir la meilleure précision absolue mais d'avoir un système qui répond vite, qui ne bloque pas et qui permet d'enchaîner des tests dans de bonnes conditions.



Figure 17 : Mise en situation des tests

Le protocole de test était volontairement simple, parce qu'on n'avait pas encore de convoyeur motorisé. On plaçait donc l'objet sous la caméra, comme présenté à la Figure 17 afin de garder des conditions assez constantes (distance, angle, éclairage). Ensuite, on déplaçait l'objet à la main vers la zone des ultrasons jusqu'à ce que le capteur détecte la présence. À ce moment-là, le "bon" piston devait s'activer. Cette méthode permettait de valider la synchronisation "logique" du système, l'IA définit le label mais l'action mécanique s'enclenche que lorsque l'objet est physiquement au bon endroit ce qui évite de déclencher trop tôt ou trop tard.



Figure 18 : Objets plastiques utilisés pour les premiers tests

Pour ces premiers tests, on a essayé plusieurs objets plastiques (Figure 18). On avait notamment plusieurs objets PET (bouteilles, flacon de gel, bouteille écrasée). Sur ces objets PET, les résultats étaient très bons, la classification sortait “PET” avec une confiance maximale dans nos essais (Figure 19 et Figure 21). Ce comportement est cohérent avec la base de données utilisée où l’on retrouve beaucoup d’exemples de bouteilles y compris écrasées et sous différents angles. Ça montre que le modèle arrive à généraliser sur des variations réalistes et pas uniquement sur des images “propres”.

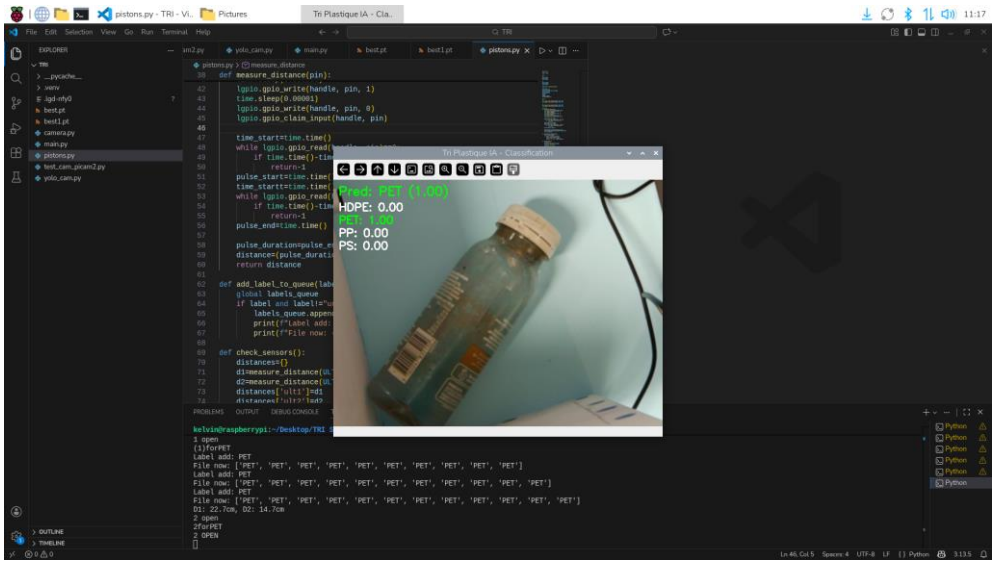


Figure 19 : Exemple de test PET reconnu à 100%

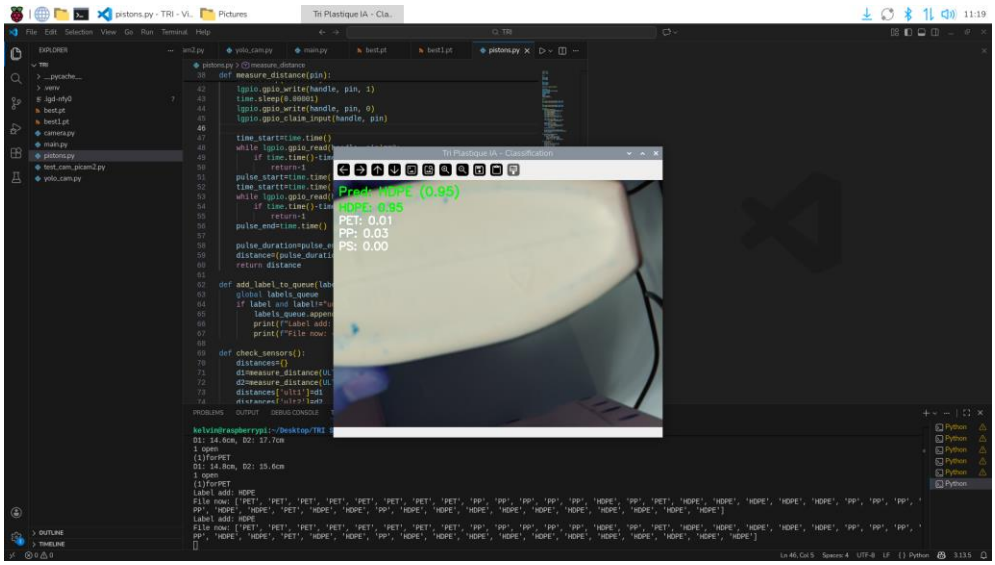


Figure 20 : Exemple HDPE reconnu correctement après changement d'orientation

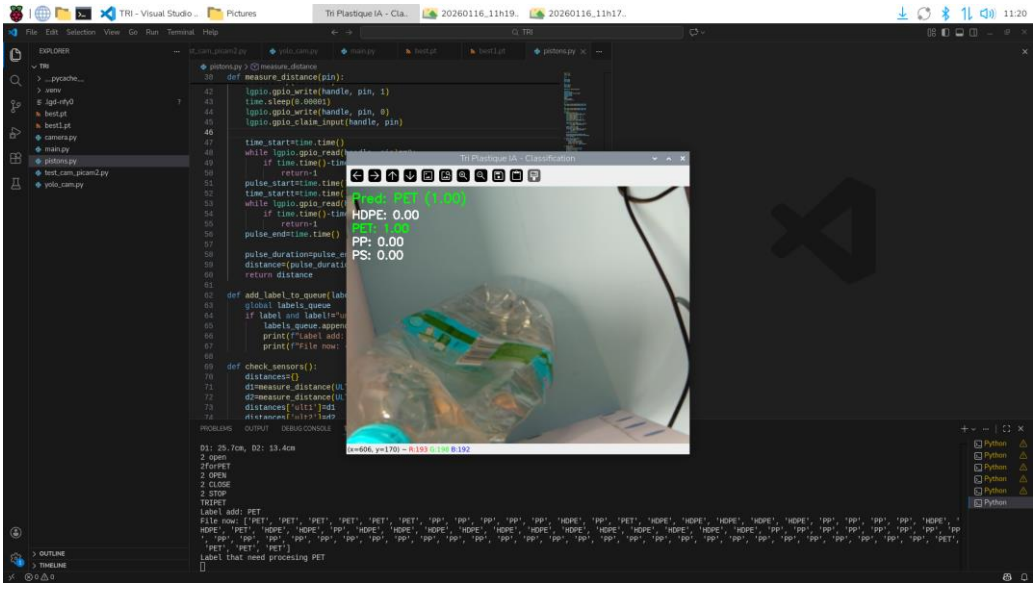


Figure 21 : Exemple PET (bouteille) reconnu à 100%

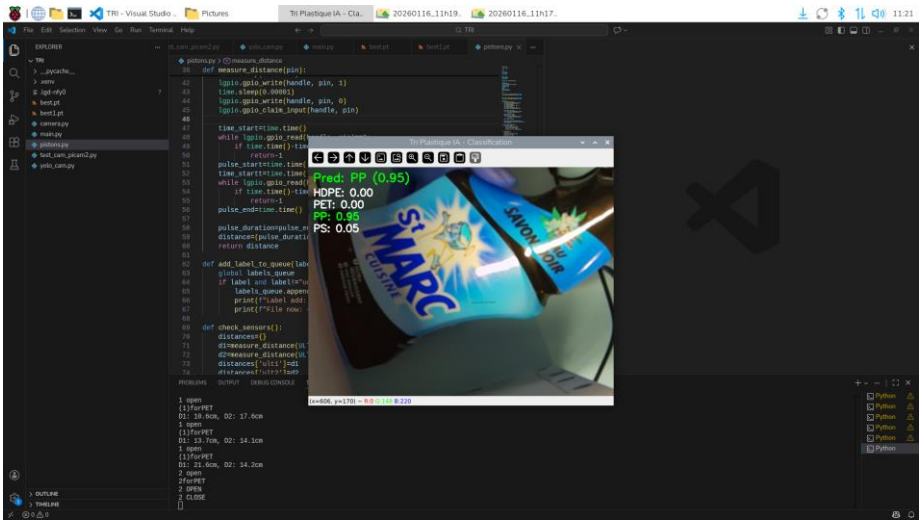


Figure 22 : Cas limite : l'objet HDPE est prédit PP avant d'être retourné

Pour le HDPE, on constate quelque chose d'intéressant, le label "HDPE" était parfois mal reconnu selon la face présentée à la caméra et l'apparence dominante dans l'image. On a eu un cas où, dans une 1ère position, le modèle a prédit PS avec une confiance non négligeable (Figure 22). En pratique, ce n'est pas forcément "illogique", selon l'éclairage, les reflets et surtout si l'on ne voit qu'une partie de l'objet (ou une zone très uniforme), le modèle peut se raccrocher à des indices visuels incomplets et se tromper de famille. Ensuite, en retournant l'objet et en montrant davantage la partie blanche (donc avec des indices plus "lisibles" et moins perturbés), la prédiction est redevenue correcte et on a obtenu "HDPE" avec une confiance élevée (Figure 20). Ce test illustre bien une limite réelle d'un système de vision, la matière ne change pas mais l'apparence change énormément selon l'étiquette, la couleur, l'orientation, les reflets et la face présentée. C'est exactement pour ça qu'on insiste sur l'éclairage stable, le fond contrôlé et aussi sur des règles de robustesse comme le seuil de confiance (quand ce n'est pas sûr, on préfère sortir "unknown" plutôt que déclencher un tri faux).

On a aussi eu un autre cas de figure où le même objet (en réalité HDPE) a été prédit PP mais vu sous un autre angle et avec une apparence différente. Là encore, c'est un bon exemple de ce qui se passe en conditions réelles, un flacon avec une étiquette, des zones brillantes et une forme qui peut rappeler d'autres plastiques peut faire basculer la décision, surtout si l'image ne met pas en avant les mêmes indices visuels. L'intérêt de ces essais, ce n'est pas seulement de dire "ça marche" mais justement d'identifier les cas limites dûs aux objets sombres, étiquettes contrastées, zones très brillantes et orientation défavorable. Ça nous donne une direction claire pour la suite, enrichir le dataset avec plus de variabilité (notamment des HDPE avec emballages

sombres/étiquettes), stabiliser encore l'éclairage et continuer à appliquer une logique de décision robuste basée sur la confiance.

Pour finir, cette maquette a vraiment joué son rôle, elle nous a permis de valider l'intégration mécanique (trous, placements, maintien), l'intégration électronique (capteurs, relais, actionneurs) et le principe de test en conditions proches du réel tout en identifiant très tôt les limites liées aux performances de calcul et à la variabilité visuelle des déchets. C'est exactement ce qu'on voulait avant de passer à une version plus "propre" et plus proche d'un prototype final.

Conclusion et perspectives

Dans l'ensemble, le projet a bien abouti et on peut dire que le planning (Gantt) ainsi que le cahier des charges ont été globalement respectés. On a réussi à suivre les grandes étapes prévues qui est de comprendre le besoin, choisir le matériel, développer la partie logicielle, intégrer le tout sur une maquette et valider le fonctionnement par des tests. La seule partie qui n'a pas été menée aussi loin qu'on l'aurait voulu concerne les améliorations et l'optimisation, principalement par manque de temps et surtout en étant seulement 2 dessus. On préfère donc garder ces points comme perspectives pour une suite future du projet.

Au niveau du résultat, le système fonctionne, la caméra récupère l'image, le modèle IA réalise la classification du plastique et ensuite les pistons s'activent pour pousser le déchet dans la bonne benne/zone de tri. On a donc bien validé la chaîne complète vision → décision IA → synchronisation capteur → action mécanique, ce qui était l'objectif principal du prototype.

Le principal défaut identifié vient surtout de la base de données utilisée pour l'entraînement. Dans le dataset, même s'il y avait parfois des emballages, ils étaient généralement moins "marquants" : on arrivait encore à distinguer clairement l'objet et sa matière. Dans notre cas réel, certains déchets (comme le HDPE) sont presque entièrement recouverts par l'emballage/étiquette, ce qui change totalement l'apparence visuelle. Du coup, le modèle a tendance à se baser sur ce qu'il "voit" (couleurs, motifs, contraste) et peut se tromper si l'étiquette domine l'image. C'est pour ça que sur le HDPE, on a réussi à le reconnaître seulement sous certains angles ou quand une partie plus représentative du plastique (moins recouverte) était visible.

Pour les perspectives, la première amélioration évidente serait d'intégrer un vrai convoyeur motorisé. Pendant nos essais, on déplaçait les plastiques à la main, ce qui ne représente pas complètement les conditions réelles de vitesse, de cadence et de

positionnement sur tapis. Un convoyeur permettrait de tester le système en temps réel, avec une vraie synchronisation et des scénarios plus proches d'un centre de tri.

Enfin, une autre piste intéressante serait d'élargir la détection à d'autres déchets spécifiques, par exemple les piles, batteries ou petits objets dangereux. L'idée serait d'ajouter ces nouvelles classes dans l'entraînement pour que le système puisse non seulement trier des plastiques, mais aussi repérer des éléments critiques et améliorer la sécurité et l'efficacité du tri global.

Références Bibliographiques

Documents Industriels et Rapports

[1] Unilys / Valoseine. (2023). *Données d'exploitation du centre de tri Cyrène : Tonnage de la collecte sélective (Bac jaune)*. Volume annuel : 10 641 tonnes.

https://unilys.fr/accueil/valoseine/cyrene/

[2] COTREP & Citeo. (n.d.). *Guide technique pour la recyclabilité des emballages ménagers*. Principes du tri optique (NIR-VIS) et standards de détection.

https://www.cotrep.fr/content/uploads/2019/02/2021-cotrep-protocole-test-tri-optique-emballages-sombres-v1-1.pdf

[3] France Travail. (2025). *Enquête Besoins en Main-d'œuvre (BMO) 2025*. Statistiques régionales Île-de-France : Taux de difficulté de recrutement (41,9 %).

https://statistiques.francetravail.org/bmo/bmo?pp=2025&ss=1

Données Économiques et Fournisseurs

[4] HelloPro. (2024). *Catalogue équipements industriels : Trieurs optiques*. Fourchette de prix observée : 30 000 € – 200 000 €.

https://conseils.hellopro.fr/combien-coutent-les-materiels-de-triage-alimentaire-2450.html

[5] France Environnement. (2024). *Solutions de traitement des déchets : Cribles et équipements de pré-tri*. Estimation : 80 000 € – 227 850 €.

https://www.franceenvironnement.com/sous-rubrique/crible%2C-precrible

[6] HelloPro. (2024). *Lignes de tri automatisées complètes*. Ordre de grandeur d'investissement : ~500 000 €.

https://conseils.hellopro.fr/combien-coute-un-centre-de-tri-de-dechets-2765.html

Articles Scientifiques et Techniques

[7] Bobulski, J., & Kubanek, M. (2021). "Deep Learning for Plastic Waste Classification System". *Applied Computational Intelligence and Soft Computing*, vol. 2021.

[8] Nahiduzzaman, M., et al. (2025). "Compact Deep Learning Models for Real-time Waste Classification". *Knowledge-Based Systems*.

[9] Martinez-Hernandez, A., et al. (2024). "Low-cost approach for plastic sorting using Multi-spectral VIS–NIR sensors and Deep Learning". *Sensors*.

[10] Xia, J., et al. (2021). "Plastic waste identification using NIR spectroscopy combined with Convolutional Neural Networks". *Waste Management & Research*.